外形修改实验
问卷设计说明

用户的要求不够明确时，虚拟角色应该先问，还是先做一个容易检查和撤销的修改？

> 本轮研究问题
> 在共同的 Unity + DeepSeek 系统中，选择性澄清与直接执行、总是询问、模型自主决定相比，怎样改变目标达成、打断和修复之间的权衡？

问卷补上日志看不到的体验

系统日志能够记录是否改对、问了几次、修复了几次。我们还需要知道参与者是否觉得被打断、是否能控制修改，以及完成任务需要多少精力。因此，每轮之后都填写相同的四项体验题，最后再比较偏好。

从论文出发，形成自己的假设

Jung 等人的研究比较文本和图像生成中的不提问、先问与后问。作者发现，澄清带来了一些信任收益，也增加了沟通努力；多数体验指标没有显示明显的时机差异。我们由此分别测量澄清的成本与体验收益。[1]

选择性澄清是否更好，仍需由本项目的实际数据回答。论文中的任务、条件和问卷均与本轮不同，我们没有把其结果直接视为外形实验的结论。

2026年10月19日 · 中文全流程问卷 v4
本文件供队友准备PPT。完整题目、规则、过程和字段映射见配套Markdown。

用同一套系统，比较何时提问

Unity显示角色并执行修改，DeepSeek理解请求和生成候选，共同harness管理状态、执行校验、澄清、撤销和日志。四条件都使用相同的角色与交互界面。

用户请求 → 共同候选 → 策略决定问或做 → 修改与撤销

条件	对可支持的初始请求怎样处理
E · 直接执行	采用共同默认候选，之后允许检查和修复。
A · 总是询问	先问一次；明确请求也进行确认。
N · 原生模型决策	DeepSeek自主决定询问、执行或无法解决，不接收选择性规则。
S · 选择性澄清	按引用、偏好和候选分歧判断，并允许小幅可逆修改先执行。

S的触发规则

检查顺序	行为
R1：历史引用不清	存在不同候选时先问；无法形成消歧选项时记录为未解决。
R2：可能覆盖旧软偏好	证据同时表明存在覆盖，且用户未明确改变偏好时先问。
小步可逆例外	仅修改比例，默认变化及候选跨度均不超过0.05，且未触发R1/R2时先做。
R3：候选有实质分歧	修改字段不同、颜色/配饰不同，或比例跨度达到0.10时先问。

其余情况执行共同默认候选；超出能力范围的请求走共同的未解决出口。候选最多三个并按结果去重，所有问题都有“其他 / 都不是”和取消选项。证据仍可能被模型误读，明确规则并不保证判断正确。KnowNo提供了按不确定性寻求帮助的参考，本项目没有复现其统计保证。[2]

每人四轮，控制任务与信息

4	4	16
策略条件	每轮任务	每人计划试次

任务包含明确修改、小幅模糊调整、多种实质解释、历史与偏好四类，准备四套匹配变体。每个参与者不重复同一道具体任务。

先做可观察、可撤销的外形变化

本轮修改外衣颜色、配饰和整体比例。初始请求使用固定文本，澄清采用共同选项面板，修复方式也一致。这样能先检验控制信息量下的决策，语音识别和播报留到后续研究。

与原生LLM的公平比较

四条件共用候选、默认修改、上下文、问题模板、界面和修复预算。模型与规则都看不到参与者的私有目标卡，也看不到评分器。N只承担自主决定问或做的职责，因此称为Native-gate；完全自由运行的agent会同时改变规划和问题内容，应单独比较。

N可能增加一次模型调用。我们记录实际等待与费用，不用人工延迟其他条件来制造等时。候选生成器不接收条件代码；API随机性造成的候选差异需记录。

顺序与人数

四条Williams顺序用于平衡条件位置与先后影响。原安排包含2个预实验槽位、20个正式槽位，实际人数尚未确定。人数不足时沿用固定分配顺序，报告真实完成和退出情况。

> 22是原招募目标。20个正式槽位和320条计划试次都不是已收集数据。预实验与调试数据不补进正式样本。

初始澄清最多一次，修复/撤销最多两次，试次上限暂定120秒，预实验后冻结。当前工程证据来自Ubuntu桌面，新的外形界面尚未完成PICO/XR验证。

一次打开，按实验顺序填写

问卷合并为六页32题。参与者填写一次编号和实验类型，四轮之间保留页面，全部结束后统一提交。仅前三题必答，其余29题可以跳过。

页面	题号	内容与目的
开始前	Q1至Q7	编号、类型、参加同意、经验和可选旧问卷关联。
第1轮之后	Q8至Q12	每轮相同的四项体验评分，加一项选填补充。题干一致，便于参与者内比较。
第2轮之后	Q13至Q17	
第3轮之后	Q18至Q22	
第4轮之后	Q23至Q27	
全部结束后	Q28至Q32	偏好、理由、有帮助和没必要的提问、改进建议。

每轮重复的四项题目

1. 系统的提问打断了我完成任务的过程。
2. 我能控制哪些外形特征会被修改。
3. 完成这些修改需要我投入很多精力。
4. 我对这一轮修改外形的体验感到满意。

按1至7级同意度作答，另设“无法判断 / 不想回答”，无默认选项。没有提问时，打断题提示选择1。打断和努力的高分表示负担更高，控制和满意度的高分表示体验更积极。

> 四项都是自拟单题，分别分析。没有验证为标准量表，也不相加得到“体验总分”。努力增加可能来自有效思考，需要结合成功率和开放回答解释。

最终偏好只显示第1至第4轮。参与者看不到E/A/N/S标签，也不会被题目提示哪一轮是研究者提出的策略。当前问卷不直接测量信任。

所有人共用一台设备

同一个人四轮之间保持页面打开；换人时关闭上一份作答，重新打开空白入口，确认编号、实验类型和答案均为空。实验类型选调试、预实验或正式实验，参与者编号仍用于对应操作日志。

同意与选填逻辑

Q3同意后才显示后续研究题。Q7旧匿名编号还要求Q6同意关联，两个条件同时满足。拒绝参加时结束流程；旧问卷关联不影响本次参与。

已检查设备/IP/微信限答、断点续答、旧答案回填和总份数控制的已找到设置，均为关闭。上一页可保留当前人的答案，新开预览为空白。尚未通过连续真实提交验证同设备重复填写。

日志和问卷各自记录什么

来源	数据与解释
系统与渲染日志	首次与最终结果、三次外形保持检查、提问/修复/撤销、附带误改、候选遗漏、超时及等待。
问卷	四轮体验评分、最终偏好、具体提问例子和改进建议。
研究者分配表	参与者编号、轮次到策略的对应、任务集、完成与退出情况。

一份问卷是一人一次实验。导出时把四个评分块展开成四条分轮记录，再与日志对应。空白和“无法判断 / 不想回答”保留为缺失，普通单选的第8个选项不能算作8分。

> 已发现的线上边界
> 撤回旧问卷关联许可后，Q7会隐藏，但前端旧值仍在。分析必须以实际许可为准。拒绝路径仍有提交控件，服务端是否保存未验证；现场拒绝时直接结束，不要求提交。

研究者需在正式采集前说明访问权限、存储位置、保留期限和撤回方式。真实问卷星导出列头、隐藏字段入库及独立账号限答也仍有待核验。

先报告完成证据，再报告实验结果

预定怎样判断效果

主要客观指标是稳定目标达成：在共同时间与修复预算内达到目标，保留不应改变的属性，并通过三个后续保持探针及实际渲染检查。首次执行正确率在修复之前单独记录。

主要比较每人S与N的稳定成功率差；次要比较S与A的询问和打断、S与E的首次成功率。展示参与者内差值与不确定性区间，四项主观评分分别分析。小样本没有显著差异，不能解释为两种策略等效。

已经完成到哪里

已有证据	不能据此宣称
Unity桌面原型和后端；四策略、外形修改、澄清、撤销与日志。	PICO沉浸式交互已完成验证。
最新14项交互/渲染检查通过，使用mock provider，参与者答卷0份。	已经获得真实用户体验结果，或该轮完成了真实API验证。
中文问卷32题六页已保存重载核对，并完成发布。	同设备连续提交和全部服务端存储行为都已验证。

队友制作PPT的建议顺序

1. 用“少问可能省事，也可能改错”说明研究动机。
2. 展示共同系统与四种决策策略，再给出S的规则示例。
3. 说明每人四轮、任务与顺序控制，以及六页问卷的测量目的。
4. 展示已核验的原型和问卷，列出预实验、正式采集及PICO验证的剩余工作。

旧问卷含模拟及来源未核实的记录，不能计入真人结果。人类何时提问也不等同于模型何时需要信息，因此本轮同时评估实际执行与体验。[3] 真正的策略优劣、样本数和结果图须在采集后补充。

问卷已发布

虚拟角色外形修改研究（全流程）

https://v.wjx.cn/vm/QZCoEdh.aspx

问卷编号389439995
2026年10月19日20:59发布
21:02核验：已发布、0答卷
32题 · 六页 · 一人最后提交一次

这份材料怎样使用

PDF可用于梳理PPT叙述；配套《问卷完整设计与题目.md》保留完整设计过程、全部32题的题干与选项、显示条件、字段映射、分析计划和未验证事项。文案已按humanizer复核，保留事实、题意和实验边界。

现场使用时，一位参与者从开始前填写到最后回顾，最后提交一次。下一位参与者重新打开空白入口。发布核验没有提交任何测试答卷。

文献依据

[1] Jung, G., Ho, H. Y., Quartson, P., & Cheshire, C. (2026). *Ask Before or After? Clarification Timing and User Experience in Generative AI.* Creativity and Cognition.
doi.org/10.1145/3803784.3816856

[2] Ren, A. Z., et al. (2023). *Robots That Ask For Help: Uncertainty Alignment for Large Language Model Planners.* CoRL, PMLR 229.
proceedings.mlr.press/v229/ren23a.html

[3] Testoni, A., & Fernández, R. (2024). *Asking the Right Question at the Right Time: Human and Model Uncertainty Guidance to Ask Clarification Questions.* EACL.
aclanthology.org/2024.eacl-long.16/

问卷版本：appearance-survey-v0.1-zh-CN.4-unified
记录依据：统一JSON、实验协议、规则代码、工程验证与问卷星发布记录。
作者原论文已核对本地PDF；[2][3]本次复核出版页与摘要。